陆金所AI SQL审核系统介绍

王英杰

陆金所数据架构团队负责人









收获国内外一线大厂实践 与技术大咖同行成长

☞ 演讲视频 ☞ 干货整理 ☞ 大咖采访 ☞ 行业趋势



- 1. 项目背景
- 2. 研发过程
- 3. 未来展望

- 1. 项目背景
- 2. 研发过程
- 3. 未来展望

1. 项目背景

- SQL的性能对核心系统可用率至关重要。
- 人工SQL审核系统会遭遇开发和DBA的人力资源瓶颈。

1.1 人工SQL审核流程

01代码提交



() 2 差异比较



人工SQL审核系统特点:

- 人工SQL审核系统对所有应用、每个版本下的每一笔SQL进行管理
- **审**核系**统**会自**动**生成每个版本的SQL文本差异以及**导**致的**执**行**计**划差异
- 开**发**和DBA会**审**核每个版本里**发**生**变**更的SQL、**导**致的**执**行**计**划差异以及 对性能的影响
- **发**版平台**对**于人工SQL**审**核系**统**建立强依**赖**

03人工审核



04上线批准




1.2 人工SQL审核平台

« prev ✓ 通过的意见 ∨	
SQLMAP 差异 执行计划 DBA 建议(通过)	
dev_20190925_06 【该 SQL含有动态拼接,请dba 注意!】	reg_20190911_01
[执行计划(错误信息)] Plan hash value: 2217901320	[执行计划(错误信息)] *** Plan hash value: 428497240
Id Operation	Id Operation Name Rows Bytes Cost (%CPU) Time 0 SELECT STATEMENT 1 81 4 (25) 00:00:01 1
Predicate Information (identified by operation id):	Predicate Information (identified by operation id):
3 - access("T"."IS_VALID"='1')	2 - filter("T"."IS_VALID"='1')
[sql文本] /*@ files=be_productLineMerchantIdRel.xml namespace=ProductLineMerchantIdRel id=findProductLineList @*/	[sql文本] /*@ files=be_productLineMerchantIdRel.xml namespace=ProductLineMerchantIdRel id=findProductLineList @*/
/*isNotEmpty property='accPlatformType' prepend='and'*/ and	
acc_platform_type =:P_accPlatformType /*isEmpty property='accPlatformType' prepend='and'*/ and	
(acc_platform_type <> '5' or acc_platform_type is null)	





1.3 审核流程的展开



- 审核和分类过程就是一个打标签数据的过程
- 打标签过程需要大量的开发和DBA人力资源



- 1. 项目背景
- 2. 研发过程
- 3. 未来展望



2. 研发条件

- 人工SQL审核系统运行了3年,我们有了下面这些数据:
 - > 每个应用版本的SQL代码改动数据和当时在生产环境的执行计划变动数据
 - > 每个应用版本上线前后的数据字典和统计信息备份
 - > 每个应用版本上线前DBA的审核意见数据
 - > 每个应用版本上线后在每笔SQL在生产环境的运行时效数据
- 那么,是否可以基于历史数据 + AI算法来模拟DBA对SQL的审核?




2.1 研发思路

- 找到SQL代码、执行计划、统计信息、绑定变量和执行效率之间的相关性。
- 通过相关性基于SQL代码、执行计划、统计信息、绑定变量来预测执行效率。

2.2 第一个版本——实现对SQL执行效率的预测

● 找SQL各个维度的信息和生产执行效率的相关性






2.2 特征嵌入


目标:将模型不可读的TEXT格式转换为可读的数字格式

- SQL语句使用tf-idf(词频逆文档频)转化
- 执行计划使用素数编码转化





2.2 信息压缩+特征提取







2.2 对SQL的执行时长进行预测

使用线性回归对SQL的执行时长进行预测:

- 在生产环境选取300条SQL按照执行时长从低到高排序,生成实际曲线(橙色)
- 使用线性回归生成预测曲线(蓝色)










2.2 在陆金所上线后的效果

- 基于拟合度下,把AI作为SQL审核平台的第一道环节,AI审核通过即直接上线,人工不再审核。
- SQL审核总量里80%的SQL都是符合性能预期的,这些SQL由AI直接审核后上线,也节省了80%的人工审核工作量。






2.3 第二个版本——实现对SQL优化方案的搜索






2.3 方案的选择




频率派 P(Y,X)



贝叶斯派 P(Y|X) ~ P(X|Y)P(Y)



2.3 基于贝叶斯的启发式搜索






2.4 特征预处理:LUparser—陆金所SQL解析器

目标:


- ●解析出SQL中列,表, 查询条件,子查询或视图的连接关系, 把信息保存在有向图(direct graph)。
- 为了让机器能看懂SQL代码的结构。





2.4 LUparser—陆金所SQL解析器

Luparser的SQL解析过程,为了让机器能读懂SQL代码的结构。



SQL语句



基于正则化方法,将SQL转换成精度不高的AST



深度优先完全遍历

深度优先遍历,并存入图。


- 图会以 id 和 type 分别存入到两个哈希表中 为什么深度优先:希望能保存tokens的前后关 系,方便未来SQL重写




基于节点的type 从(SUB > TAB > COL) 依次 建立连接关系



2.5 基于贝叶斯的启发式搜索






- · 状态(S) : python方法 ,输出必须包含数值(计算启发值)
- 状态到状态:通过启发函数来选择。
- 搜索终止条件:当发现没有可选的状态,或候选状态为空

2.5 训练启发函数



- 1. 对DBA建议做分词
- 2. 同义**海茱缎**定抓取关†算联合概率键字,**应新俄搜索**也图

1.基于历史评审意见



2.基于DBA经验对函数做调整

- · 状态修正
- e.g. 索引问题更倾向于查找区分度和直方图

2.6 陆金所上线后的效果

- 上线前对接代码库和发版平台,对审核不通过的SQL,先给出一轮优化建议供开发和DBA参考。
- 上线后对接监控平台,监控平台捕获慢查询后,调用AI SQL审核服务接口,自动给出优化建议。
- 同时AI明确优化建议优于CBO的执行计划才会给出建议反馈。





2.7 真实案例介绍

• 基于启发式搜索查找最优索引策略。

```
select
                  id id,
                  created_at createdAt,
                  created_by createdBy,
                  updated_at updatedAt,
                  updated_by updatedBy,
                  user_id userId,
                  activity_id activityId,
                  task id taskId,
                  status status,
                  crm_user_id crmUserId,
                  SYNC_CHECK syncCheck,
                  REF_ID refId,
                  BATCH_ID batchId,
                  partition_key partitionKey
              from act_task_result
              task_id = :P_taskId
              and id >= :P_startId
              and id <= :P_endId</pre>
              and partition_key in
22 /*iterate property='partitionKeyList' close=')' conjunction=',' open='('*/
              :P_partitionKeyList
              :P_partitionKeyList
              :P_partitionKeyList
       *isNotEmpty property='status' prepend='and'*/ and
```








- 一项目背景
- 二. 研发过程
- 三. 未来展望



3.1 背景


• 贝叶斯派基于DBA经验,也受限于DBA经验。

能否通过强化学习让AI训练出突破现有DBA经验的优化方案。





3.2 第三个版本——基于对抗模型的算法








InfoQ官网全新改版上

促进软件开发领域知识与创新的传播





关注InfoQ网站 第一时间浏览原创IT新闻资讯



免费下载迷你书 阅读一线开发者的技术干货

THANKS

_

Global
Architect Summit



